

Práctica Nro. 5

PARTE I. Datos abiertos

1. Investigar y mencionar 3 sitios de datos abiertos donde se puedan obtener datasets relevantes para diferentes análisis a realizar. Describa el tipo de datos que se puede encontrar en cada uno.

Sitios:

- <https://www.airroi.com/data-portal/>
 - Se pueden encontrar archivos en formato .csv, json, y Apache Parquet
 - **Nivel de apertura:** Tercer nivel (se utilizan formatos estructurados y libres para que lo procese cualquier software)
- <https://data.buenosaires.gob.ar/>
 - Se pueden encontrar datos en formato tabulado (.csv), excel (.xlsx), json, geojson, shp, entre otros.
 - **Nivel de apertura:** Segundo nivel (hay archivos que tienen extensiones de software propietario)
- <https://www.gub.uy/ministerio-educacion-cultura/datos-y-estadisticas/datos>
 - Se pueden encontrar archivos en formato excel (.xlsx)
 - **Nivel de apertura:** Segundo nivel (hay archivos que tienen extensiones de software propietario)

2. ¿Cuál es la diferencia entre datos públicos y datos abiertos?
Proporciona un ejemplo de cada tipo

Según la página oficial del gobierno datos.gob.ar, un **dato público** es "cualquier dato generado en el ámbito gubernamental, o que se encuentra bajo su guarda", mientras que el **dato abierto** es un dato de cualquier origen, sea público o no, cuyo acceso, uso y compartición se encuentra libre para cualquiera que lo quiera

usar, "sólo deben atribuirse y compartirse con la misma licencia con la que fueron publicados. Son, a su vez, datos públicos disponibilizados en un medio digital, bajo una licencia abierta y usando para ello un formato estándar abierto".

- La diferencia entre uno y otro radica en sus propiedades y su uso. Que el dato sea público no garantiza que se pueda acceder, utilizar y compartir libremente.

3. Mencione 3 tipos de licencias que pueden tener los datos abiertos, describiendo diferencias entre ellas.

Tres tipos de licencias que pueden tener los datos abiertos son:

- **Open Data Commons Open Database License (ODbL)** → Permite usar, distribuir, copiar, crear trabajos a partir de, modificar, transformar, y construir sobre los datos, mientras se respeten las siguientes pautas: Atribuir autoría, mantener la misma licencia, y mantener una copia del dataset libre
- **Creative Commons Zero** → Se renuncian a todos los derechos como autor de la obra, en este caso los datos. Los datasets se pueden utilizar de la forma que sea y sin necesidad de atribuir autoría
- **Open Data Commons Public Domain Dedication and License (PDDL)** → Igual a la CCZ, permite hacer lo que sea con los datos sin restricciones

4. Suponga que tiene acceso a un dataset abierto sobre los niveles de contaminación del aire en diferentes ciudades del país. ¿Qué tipos de análisis podría realizar para obtener información útil?

- Podría hacer análisis estadísticos para detectar tendencias en las ciudades del país y poder así encontrar problemáticas que afectan a la sociedad y al ecosistema, y ver como tratarlas. También se podrían realizar análisis económicos, si la contaminación está relacionada con un sector de la economía, y también sociológicos si también hay un componente social en la cuestión, como lo puede ser la alimentación con la industria de carne vacuna, o la preferencia de los autos como medio de transporte

5. ¿Cuáles son las condiciones de la licencia creative commons?

Las condiciones de la licencia Creative Commons Atribución 4.0 Internacional son las siguientes:

- **Atribución** → En cualquier explotación de la obra autorizada por la licencia será necesario reconocer la autoría
- **No comercial** → La explotación de la obra queda limitada a usos no comerciales
- **Sin obras derivadas** → La autorización para explotar la obra no incluye la posibilidad de crear una obra derivada
- **Compartir igual** → La explotación autorizada incluye la creación de obras derivadas siempre que mantenga la misma licencia al ser divulgadas

6. ¿Qué significa tener datos IA-ready?

Significa tener datos que cumplen con los siguientes aspectos:

- Completitud de los datos
- Ausencia de errores e inconsistencias
- Uso de formatos adecuados, metadatos y estructuras homogéneas
- Proporcionar el contexto necesario para poder verificar que estén alineados con el uso que la IA les dará

7. ¿Cuáles son los principios FAIR-R y sus requisitos?

Los principios FAIR-R son los siguientes:

- Encontrables (F)
- Accesibles
- Interoperables
- Reutilizables
- Preparados para la IA (R)

Los requisitos son:

- Etiquetado exhaustivo
- Documentación completa del origen de los datos

- Homogeneidad de estándares y metadatos
- Cobertura suficiente que evite sesgos
- Licencias que regulen claramente su uso en IA

PARTE II. Visualización de Datos

1. Explique que es una medida y una dimensión

Una medida es un **dato cuantitativo**, osea que *se puede medir en unidades*, y una dimensión es un **dato cualitativo**, algo que permite que aquel y otros datos que compartan la misma cualidad *se juzguen* por las mismas propiedades inherentes.

2. Explique la diferencia entre un dato discreto y un dato continuo

Un **dato discreto** es aquel dato cuantitativo que *se puede medir con una cantidad finita de unidades*. Un dato continuo es aquel dato cuantitativo que *requiere de infinitas unidades*.

3. ¿Por qué es importante preparar los datos?

La importancia de la preparación de datos radica en que los datos estén publicados de tal forma que les sea fácil a las personas trabajar con ellos y que estos le puedan sacar el mejor provecho. Los datos deben ser preparados de tal forma que no estén agregados, mezclados, tengan el menor sesgo posible, sean procesables, legibles, completos, entre otras cualidades deseables.

Dadas las situaciones que se presentan a continuación, decidir qué tipo de gráfico utilizaría para visualizar la información de manera clara y efectiva. Justifique su elección indicando por qué ese tipo de gráfico es el más adecuado para cada caso

a. Comparación de suscripciones anuales por región geográfica

Se podría usar un **gráfico de barras**, ya que estos permiten comparar valores numéricos y mostrar variaciones entre categorías. Como segunda opción, si las ventas entre cada sector varían mucho, se podría pensar en un **gráfico de torta**.

b. Análisis de la distribución de las edades de clientes

- Asumo que la pregunta es por las edades y no por las ciudades

Yo usaría un **gráfico de barras**, ya que serviría para mostrar las variaciones entre las edades de los clientes.

c. Relación entre el precio y la puntuación otorgada por el cliente

Para analizar si existe una relación entre el precio de producto y la puntuación marcada por el cliente utilizaría el **gráfico de dispersión**, que es idóneo para mostrar las correlaciones entre dos variables, y en este caso manejamos dos datos cuantitativos.

d. Análisis de los préstamos de libros por género

Para visualizar la proporción de préstamos de cada género podríamos optar por un **gráfico de torta**, si la cantidad de préstamos de cada género varía bastante. Además, por lo que nos dice el enunciado, solo hay cinco géneros de libros.

e. Se han almacenado datos de registro de la temperatura promedio del mar, a partir de mediciones diarias frente a la costa de Las Toninas, un kilómetro mar adentro. Esta medición se viene realizando durante los últimos 7 años para estudios del comportamiento de la fauna del lugar



TipoGradoTemp(#tipoGradoTemp, descripcionTipoGrado)

TemperaturaRegistrada(#registroTemp, fecha, hora, valorTemp, #tipoGradoTemp)

TemperaturasPromedio(#registroProm, fecha, valorProm)

a) ¿Qué tipo de gráfico utilizará para mostrar los cambios de la temperatura promedio a lo largo del tiempo?

Para este propósito utilizaría un **gráfico de líneas**, ya que nos permite mostrar la relación de los cambios en los datos en un periodo de tiempo, en este caso la de la temperatura promedio del mar.

b) ¿Cuáles tablas son relevantes para presentar el análisis?

La segunda y tercera tabla, ya que la segunda nos da la fecha y hora de la medición, y la tercera nos da el valor de esa medición. La primera no la utilizamos porque no necesitamos saber la descripción de tipo de grado.

f. Dado el siguiente esquema de la base de datos



CategoriaEspecie(#cat_especie, cat_nombre)

EspecieIdentificada(#especie, #cat_especie, nombre_especie, cantidad)

a) ¿Qué gráfico utilizaría si se quiere visualizar la proporción de especies de cada categoría?

Al querer verse la proporción de especies de cada categoría, en definitiva miembros de un campo, lo ideal sería utilizar un **gráfico de burbujas**, que nos permite hacer comparaciones de alto nivel entre miembros de un campo justamente.

b) De todas las tablas propuestas, indicar cuál o cuáles son relevantes para presentar el análisis

Las dos serían relevantes, ya que la primera nos da el nombre de la categoría, y la segunda el nombre de la especie y su cantidad.

g. Visualización de las estadísticas de una cadena de supermercados

Yo utilizaría dos tipos de gráfico, **uno de barras** para visualizar la cantidad de productos vendidos de cada categoría para todas las sucursales, y **uno de líneas** para observar el total de ingresos de la sucursal número 10, mes a mes.

Los esquemas que tendría que utilizar serían el de Venta, el de Item_venta, y el de Producto.

Del esquema **Venta** utilizaría los siguientes atributos:

- id_venta
- fecha_venta
- id_sucursal (a menos que ya se hayan obtenido los datos de la sucursal 10)

- monto_total

Del esquema **Item_venta** utilizaría todos


Del esquema **Producto** utilizaría estos:

- id_producto
- categoria

[Corregido]

PARTE III: Graficando con Tableau

1. Crea un gráfico de barras horizontales que muestre la cantidad de usuarios para cada modelo de dispositivo. Segmenta las barras por el color del sistema operativo (iOS y Android) para identificar las preferencias de uso por sistema



2. Muestra una línea que refleje el promedio de aplicaciones instaladas y otra línea para el promedio de datos consumidos, ambos valores en función de la edad del usuario.